



Universidade do Minho
Escola de Engenharia

FORMULÁRIO

1º semestre (2011 /2012)

Índice

Intervalos de Confiança (uma amostra / duas amostras independentes).....	1
Testes de Hipótese (uma amostra / duas amostras independentes).....	1
Bom Ajuste (grandes amostras).....	2
Tabelas de Contingência.....	2
Análise da Variância.....	3
Planeamento Completamente Aleatório.....	3
Planeamento com Blocos Aleatórios	3
Planeamento Factorial com Replicações.....	4
Planeamento 2^2	5
Planeamento 2^3	6
Testes a K Médias (não paramétrico)	6
Kruskal Wallis	6
Quade.....	7
Bom Ajuste (pequenas amostras)	7
Kolmogorov	7
Lilliefors para a Normal.....	8
Lilliefors para a Exponencial.....	8
Teste às Distribuições.....	9
Kolmogorov – Smirnov	9
Smirnov Unilateral.....	9
Regressão.....	9
Regressão Linear Simples.....	9
Regressão Linear Múltipla.....	10
Regressão Não Linear	10
Independência Estocástica.....	11
Correlação de Pearson	11
Correlação de Spearman	11

FORMULÁRIO DE ESTATÍSTICA DESCRITIVA

1. MEDIDAS DE LOCALIZAÇÃO

1.1. MÉDIA

$$\bar{x} = \frac{1}{n} \sum_i x_i \quad \text{dados não-agrupados}$$

$$\bar{x} \approx \sum_k fr_k M_k = \frac{1}{n} \sum_k f_k M_k \quad \text{dados agrupados}$$

1.2. MEDIANA

$$Med = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} \quad n \text{ par}$$

$$Med = x_{\left(\frac{n+1}{2}\right)} \quad n \text{ ímpar}$$

$$Med = LI + \frac{0.5 - F_{r_A}^-}{F_{r_{Med}}^+ - F_{r_A}^-} \Delta \quad \text{representação histograma}$$

1.3. MODA

$$Mod = LI + \frac{d_1}{d_1 + d_2} \Delta$$
$$d_1 = f_{Mod} - f_A^- \quad \text{representação histograma}$$
$$d_2 = f_{Mod} - f_D^+$$

2. MEDIDAS DE DISPERSÃO

2.1. QUARTIL

$$Q_i = x_{\left(n \times \frac{i}{4}\right)}$$

Nota: $Q_2 = Med$

2.2. PERCENTIL

$$P_i = x_{\left(n \times \frac{i}{100}\right)}$$

Nota: $P_{50} = Med$; $P_{25} = Q_1$; $P_{75} = Q_3$

2.3. VARIÂNCIA

$$s^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2 \quad \text{dados não-agrupados}$$

$$s^2 \approx \frac{n}{n-1} \sum_k fr_k (M_k - \bar{x})^2 = \frac{1}{n-1} \sum_k f_k (M_k - \bar{x})^2 \quad \text{dados agrupados}$$

2.4. AMPLITUDE

$$A = x_{i_{\max}} - x_{i_{\min}}$$

FORMULÁRIO DE PROBABILIDADES

AXIOMA 1: $0 \leq P(A) \leq 1$

AXIOMA 2: $P(S) = 1$

AXIOMA 3: se A e B mutuamente exclusivos então $P(A \cup B) = P(A) + P(B)$

Propriedades

1. $P(A) + P(\bar{A}) = 1$
2. $P(\emptyset) = 0$
3. $P(\bar{A} \cap B) = P(B) - P(A \cap B)$
4. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Probabilidade Condicional

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A \cap B) = P(A | B) \times P(B)$$

Acontecimentos Independentes

$$P(A | B) = P(A)$$

$$P(B | A) = P(B)$$

$$P(A \cap B) = P(A) \times P(B)$$

Teorema de Bayes

$$P(A_N | B) = \frac{P(B | A_N) \times P(A_N)}{\sum_{I=1}^N P(B | A_I) \times P(A_I)}$$

FORMULÁRIO DE DISTRIBUIÇÕES DE PROBABILIDADE

DISCRETO

propriedades da função probabilidade:

$$1) f(x) \geq 0$$

$$2) \sum_x f(x) = 1$$

função probabilidade acumulada

$$F(x) = P(X \leq x) = \sum_{-\infty}^x f(x)$$

valor esperado

$$E(x) = \sum_x x \times f(x)$$

variância

$$V(x) = E(x^2) - [E(x)]^2$$

$$V(x) = \sum_x (x - \mu)^2 f(x)$$

CONTÍNUO

propriedades da função densidade de probabilidade:

$$1) f(x) \geq 0$$

$$2) \int_x f(x) dx = 1$$

função probabilidade acumulada

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(x) dx$$

valor esperado

$$E(x) = \int_x x \times f(x) dx$$

variância

$$V(x) = E(x^2) - [E(x)]^2$$

$$V(x) = \int_x (x - \mu)^2 f(x) dx$$

FUNÇÕES DE PROBABILIDADE

DISCRETAS

Distribuição de Bernoulli

$$f(x) = \theta^x (1 - \theta)^{1-x} \quad x = 0, 1$$

$$\mu = n\theta \quad \sigma^2 = n\theta(1 - \theta)$$

Distribuição Binomial [B(n,p)]

$$f(x) = \binom{n}{x} p^x (1 - p)^{n-x} \quad x = 0, 1, 2, \dots, n$$

$$\mu = np \quad \sigma^2 = np(1 - p)$$

Distribuição Poisson [P(λ)]

$$f(x) = \frac{\lambda^x e^{-\lambda}}{x!} \quad x = 0, 1, 2, \dots, n$$

$$\mu = \lambda \quad \sigma^2 = \lambda$$

Aproximação da Binomial à Poisson

N grande e p muito pequeno

$$\lambda = np$$

Distribuição Uniforme (discreta)

$$f(x) = \frac{1}{k} \quad x = x_1, x_2, \dots, x_k$$

$$\mu = \sum_i \frac{x_i}{k} \quad \sigma^2 = \sum_i \frac{(x_i - \mu)^2}{k}$$

CONTÍNUAS

Distribuição Uniforme [U(a,b)]

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{outros} \end{cases}$$

$$\mu = \frac{a+b}{2} \quad \sigma^2 = \frac{(b-a)^2}{12}$$

Distribuição Exponencial [EN(1/θ)]

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & x > 0 \\ 0 & \text{outros} \end{cases}$$

$$\mu = \theta \quad \sigma^2 = \theta^2$$

Distribuição Normal [N(μ,σ²)]

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\mu = \mu \quad \sigma^2 = \sigma^2$$

$$Z = \frac{X - \mu}{\sigma}$$

Aproximação da Binomial à Normal

$$\text{Condições} \begin{cases} np > 5 \\ nq > 5 \end{cases}$$

$$\mu = np$$

$$\sigma^2 = npq$$

Correcção de Yates

$$P(X \leq x) \approx P(X < x + 0.5)$$

$$P(Y \geq y) \approx P(Y > y - 0.5)$$

INTERVALOS DE CONFIANÇA E TESTES DE HIPÓTESES PARA UMA AMOSTRA

Parâmetro a estimar	Tipo de População	Dimensão da amostra	Conhece σ ?	E.T ~ Distribuição	Intervalo de Confiança	Notas
Média μ	Normal	Qualquer	Sim	$Z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$	$\bar{x} - z_{(1-\alpha/2)} \frac{\sigma}{\sqrt{n}} < \mu < \bar{x} + z_{(1-\alpha/2)} \frac{\sigma}{\sqrt{n}}$	$z_{(1-\alpha/2)}$: quantil da tabela acumulada da Normal padrão à esquerda
	Qualquer	$n \geq 30$	Não	$Z = \frac{\bar{x} - \mu}{s / \sqrt{n}} \sim N(0, 1)$	$\bar{x} - z_{(1-\alpha/2)} \frac{s}{\sqrt{n}} < \mu < \bar{x} + z_{(1-\alpha/2)} \frac{s}{\sqrt{n}}$	Estimador do desvio padrão: $\sigma \approx s$ (1)
	Normal	$n < 30$	Não	$T = \frac{\bar{x} - \mu}{s / \sqrt{n}} \sim t_{n-1}$	$\bar{x} - t_{(\alpha/2), n-1} \frac{s}{\sqrt{n}} < \mu < \bar{x} + t_{(\alpha/2), n-1} \frac{s}{\sqrt{n}}$	
Proporção binomial p	Bernoulli	$n > 30$ (2)	-	$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$	$\hat{p} - z_{(1-\alpha/2)} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} < p < \hat{p} + z_{(1-\alpha/2)} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	Estimador da proporção binomial $p \approx \hat{p} = \frac{x}{n}$
Variância σ^2	População Normal			$Q = \frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$	$\frac{(n-1)s^2}{\chi_{(\alpha/2), n-1}^2} < \sigma^2 < \frac{(n-1)s^2}{\chi_{(1-\alpha/2), n-1}^2}$	

INTERVALOS DE CONFIANÇA E TESTES DE HIPÓTESES PARA DUAS AMOSTRAS

Parâmetro a estimar	Tipo de População	Dimensão da amostra	Conhece σ ?	E.T ~ Distribuição	Intervalo de Confiança	Notas
Diferença entre as médias $\mu_1 - \mu_2$	Normais	Quaisquer	σ_1 e σ_2 Sim	$Z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$	$(\bar{x}_1 - \bar{x}_2) \pm z_{(1-\alpha/2)} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$	
	Quaisquer	$n_1 \geq 30$ e $n_2 \geq 30$	σ_1 e σ_2 Não	$Z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \sim N(0, 1)$	$(\bar{x}_1 - \bar{x}_2) \pm z_{(1-\alpha/2)} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$	Estimadores dos desvios padrão: $\sigma_1 \approx s_1$, $\sigma_2 \approx s_2$
	Normais	$n_1 < 30$ e $n_2 < 30$	σ_1 e σ_2 Não e $\sigma_1^2 = \sigma_2^2$	$T = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{GL}$	$(\bar{x}_1 - \bar{x}_2) \pm t_{(\alpha/2), GL} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$	$GL = n_1 + n_2 - 2$ $s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$
	Normais Amostras dependentes	$n_1 < 30$ e $n_2 < 30$	σ_1 e σ_2 Não	$T = \frac{\bar{D}_i - (\mu_1 - \mu_2)}{\frac{s_{D_i}}{\sqrt{n}}} \sim t_{(n-1)}$	$\bar{D}_i - t_{(n-1), \alpha/2} \cdot \frac{s_{D_i}}{\sqrt{n}} < \mu_1 - \mu_2 < \bar{D}_i + t_{(n-1), \alpha/2} \cdot \frac{s_{D_i}}{\sqrt{n}}$	$S_{D_i} = S_{n-1}$ para $D_i = X_{li} - X_{2i}$
Diferença de proporções $p_1 - p_2$	Bernoulli	$n_1 \geq 30$ e $n_2 \geq 30$	-	$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}} \sim N(0, 1)$ (3)	$(\hat{p}_1 - \hat{p}_2) \pm z_{(1-\alpha/2)} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$	Estimadores das proporções binomiais (4) $\hat{p}_1 = \frac{x_1}{n_1}$ e $\hat{p}_2 = \frac{x_2}{n_2}$
Razão de variâncias $\frac{\sigma_1^2}{\sigma_2^2}$	Normais	Quaisquer	-	$F = \frac{s_1^2 / \sigma_1^2}{s_2^2 / \sigma_2^2} \sim F_{v_1, v_2}$	$\frac{s_1^2}{s_2^2} \frac{1}{F_{(\alpha/2), v_1, v_2}} < \frac{\sigma_1^2}{\sigma_2^2} < \frac{s_1^2}{s_2^2} \frac{1}{F_{(1-\alpha/2), v_1, v_2}}$	$v_1 = n_1 - 1$ e $v_2 = n_2 - 1$ $\frac{1}{F_{(1-\alpha/2), v_1, v_2}} = F_{(\alpha/2), v_2, v_1}$

(1) O desvio padrão σ , sendo desconhecido, é estimado através de $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$; **(2)** Proporção para amostras de pequena dimensão necessário recorrer à solução exacta através da distribuição binomial; **(3)** e **(4)** No teste à diferença de proporções se $H_0 : p_1 - p_2 = 0$, a E.T. passa a ser $Z = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1)$, com $\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$.

Teste do "bom ajuste" do Qui-Quadrado para grandes amostras

- Probabilidades completamente especificadas na hipótese nula

$$H_0: p_1 = p_{10}, p_2 = p_{20}, \dots, p_k = p_{k0} \quad \text{e} \quad p_{10} + p_{20} + \dots + p_{k0} = 1.$$

$$\text{R.R: } Q \geq c \text{ com } c = \chi_{k-1, \alpha}^2$$

- Probabilidades não totalmente especificadas na hipótese nula

$$H_0: \text{as probabilidades correspondentes das classes provêm de uma distribuição da família ...}$$

$$\text{R.R: } Q \geq c \text{ com } c = \chi_{g.l., \alpha}^2$$

graus de liberdade = n^o de celas - 1 - n^o de parâmetros estimados

$$Q = \sum_{i=1}^k \frac{(f_i - e_i)^2}{e_i} \text{ com a frequência esperada dada por } e_i = n \cdot p_i$$

Tabelas de Contingência

		Característica B					
		B ₁	B ₂	B ₃	...	B _b	n _{i.}
Característica A	A ₁	f ₁₁	f ₁₂	f ₁₃	...	f _{1b}	
	A ₂	f ₂₁	f ₂₂	f ₂₃	...	f _{2b}	
	A ₃	f ₃₁	f ₃₂	f ₃₃	...	f _{3b}	
	⋮	⋮	⋮	⋮	...	⋮	
	A _a	f _{a1}	f _{a2}	f _{a3}	...	f _{ab}	
n _{.j}							n

1. . Teste de independência

Hipótese nula:

$$H_0: p_{ij} = p_{i.} p_{.j} \text{ (as variáveis são independentes), } i = 1, \dots, a \text{ e } j = 1, \dots, b$$

$$\text{R.R: } Q > c \text{ com } c = \chi_{(a-1)(b-1), \alpha}^2$$

2. . Teste de homogeneidade

Hipótese nula:

$$H_0: w_{1j} = w_{2j} = \dots = w_{aj} \text{ (as subpopulações A são equivalentes) para } j = 1, \dots, b.$$

$$\text{R.R: } Q > c \text{ com } c = \chi_{(a-1)(b-1), \alpha}^2$$

$$Q = \sum_{j=1}^b \sum_{i=1}^a \frac{(f_{ij} - e_{ij})^2}{e_{ij}} \text{ com a frequência esperada dada por } e_{ij} = \frac{n_{i.} n_{.j}}{n} \quad i = 1, \dots, a \text{ e } j = 1, \dots, b$$

Planeamento completamente aleatório

$$\left. \begin{aligned} SQT &= \sum_{j=1}^k n_j (\bar{y}_{.j} - \bar{Y})^2 \\ STQ &= \sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{Y})^2 \\ SQR &= \sum_{j=1}^k \sum_{i=1}^{n_j} (y_{ij} - \bar{y}_{.j})^2 \end{aligned} \right\} \left\| \begin{aligned} SQT &= \sum_{j=1}^k \frac{T_{.j}^2}{n_j} - \frac{1}{N} T_{..}^2 \\ STQ &= \sum_{j=1}^k \sum_{i=1}^{n_j} y_{ij}^2 - \frac{1}{N} T_{..}^2 \\ SQR &= STQ - SQT \quad \text{com } N = \sum_{j=1}^k n_j \end{aligned} \right.$$

$T_{.j}$ é o total dos valores obtidos para o tratamento j ; $T_{..}$ é o grande total

Tendo-se $STQ = SQT + SQR$

Modelo populacional: $y_{ij} = \mu + \alpha_j + e_{ij}$

com $i = 1, \dots, n_j$ e $j = 1, \dots, k$ $e_{ij} \sim N(0, \sigma^2)$

Teste às diferenças entre os tratamentos

$$H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

(não existem diferenças entre as médias das k populações).

H_1 : os efeitos da aplicação dos tratamentos são significativos

(ou existem diferenças entre os tratamentos).

R.R : $F > c$ em que c (Fisher) é determinado por forma a $\alpha = P[F > c; H_0]$

Tabela ANOVA

Fonte de variação	Soma dos quadrados	graus de liberdade	Média dos quadrados	v.a. F
Tratamentos	SQT	k-1	MQT=SQT/(k-1)	F = $\frac{MQT}{MQR}$
Resíduos	SQR	$\sum n_j - k$	MQR=SQR/($\sum n_j - k$)	
Total	STQ	$\sum n_j - 1$		

- Intervalos de confiança para diferenças entre pares de médias de tratamentos i e j com $i \neq j = 1, 2, \dots, k$

$$T = \frac{(\bar{y}_{.i} - \bar{y}_{.j}) - (\mu_i - \mu_j)}{\sqrt{\frac{SQR}{N-k} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}} \sim t_{N-k}$$

Planeamento com blocos aleatórios

$$\left. \begin{aligned} SQT &= b \sum_{j=1}^k (\bar{y}_{.j} - \bar{Y})^2 \\ SQB &= k \sum_{i=1}^b (\bar{y}_{i.} - \bar{Y})^2 \\ STQ &= \sum_{i=1}^b \sum_{j=1}^k (y_{ij} - \bar{Y})^2 \\ SQR &= \sum_{i=1}^b \sum_{j=1}^k (y_{ij} - \bar{y}_{i.} - \bar{y}_{.j} + \bar{Y})^2 \end{aligned} \right\} \left\| \begin{aligned} SQT &= \frac{1}{b} \sum_{j=1}^k T_{.j}^2 - \frac{1}{kb} T_{..}^2 \\ SQB &= \frac{1}{k} \sum_{i=1}^b T_{i.}^2 - \frac{1}{kb} T_{..}^2 \\ STQ &= \sum_{i=1}^b \sum_{j=1}^k y_{ij}^2 - \frac{1}{kb} T_{..}^2 \\ SQR &= STQ - SQT - SQB \end{aligned} \right.$$

$T_{i.}$ é o total dos valores obtidos para o bloco i ; $T_{.j}$ é o total dos valores obtidos para

o tratamento j

Modelo populacional: $y_{ij} = \mu + \alpha_j + \beta_i + e_{ij}$
para $i = 1, \dots, b$ e $j = 1, \dots, k$ $e_{ij} \sim N(0, \sigma^2)$

Teste às diferenças entre os tratamentos

$$H_{01} : \alpha_1 = \alpha_2 = \dots = \alpha_k = 0$$

(não existem diferenças significativas entre os tratamentos).

H_{11} : os efeitos da aplicação dos tratamentos são significativos

(ou existem diferenças entre os tratamentos).

R.R : $F_1 > c$ em que c (Fisher) é determinado a partir de

$$\alpha = P[F_{1,((k-1),(b-1)(k-1))} > c; H_{01}] \quad e \quad F_1 = \frac{MQT}{MQR}$$

Teste às diferenças entre os blocos

$$H_{02} : \beta_1 = \beta_2 = \dots = \beta_b = 0$$

(não existem diferenças significativas entre os efeitos dos blocos)

H_{12} : existem diferenças entre os efeitos dos blocos.

R.R : $F_2 > c$ em que c (Fisher) é determinado a partir de

$$\alpha = P[F_{2,((b-1),(b-1)(k-1))} > c; H_{02}] \quad e \quad F_2 = \frac{MQB}{MQR}$$

Tabela ANOVA

F. de variação	S. dos quadrados	graus de liberdade	Média dos quadrados	v.a. F
Tratamentos	SQT	k-1	MQT=SQT/(k-1)	$F_1 = \frac{MQT}{MQR}$
Blocos	SQB	b-1	MQB=SQB/(b-1)	
Resíduos	SQR	$(k-1).(b-1)$	MQR=SQR/ $(k-1).(b-1)$	$F_2 = \frac{MQB}{MQR}$
Total	STQ	$k.b-1$		

Intervalos de confiança para diferenças entre pares de médias de tratamentos:

$$T = \frac{(\bar{y}_{j1} - \bar{y}_{j2}) - (\mu_{j1} - \mu_{j2})}{\sqrt{MQR(\frac{2}{b})}} \sim t_{(b-1)(k-1)}$$

Planeamento factorial com replicações

$$\left\{ \begin{array}{l} SQF_A = qr \sum_{i=1}^p (\bar{y}_{i..} - \bar{Y})^2 \\ SQF_B = pr \sum_{j=1}^q (\bar{y}_{.j.} - \bar{Y})^2 \\ SQR = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^r (y_{ijk} - \bar{y}_{ij.})^2 \\ STQ = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^r (y_{ijk} - \bar{Y})^2 \end{array} \right\} \left\{ \begin{array}{l} SQF_A = \frac{\sum_{i=1}^p T_{i.}^2}{rq} - \frac{T^2}{pqr} \\ SQF_B = \frac{\sum_{j=1}^q T_{.j}^2}{rp} - \frac{T^2}{pqr} \\ SQR = \sum_{ijk} y_{ijk}^2 - \frac{\sum_{ij} T_{ij}^2}{r} \\ STQ = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^r y_{ijk}^2 - \frac{T^2}{pqr} \\ SQI_{AB} = STQ - SQF_A - SQF_B - SQR \end{array} \right.$$

T_{ij} é a soma das observações da célula (i, j)

Modelo populacional

$$y_{ijk} = \mu + \alpha_i + \beta_j + \gamma_{ij} + e_{ijk}$$

para $i = 1, \dots, p$, $j = 1, \dots, q$ e $k = 1, \dots, r$ e $e_{ijk} \sim N(0, \sigma^2)$

Testes de hipóteses

• Factor A

$$H_{01} : \alpha_1 = \alpha_2 = \dots = \alpha_p = 0$$

H_{11} : existem diferenças significativas entre os níveis de A

R.R : $F_1 > c$ com c (Fisher) determinado de

$$\alpha = Pr[F_{1(p-1), pq(r-1)} > c; H_{01}] \text{ e } F_1 = \frac{MQF_A}{MQR}$$

• Factor B

$$H_{02} : \beta_1 = \beta_2 = \dots = \beta_q = 0$$

H_{12} : existem diferenças significativas entre os níveis de B

R.R : $F_2 > c$ com c (Fisher) determinado de

$$\alpha = Pr[F_{2(q-1), pq(r-1)} > c; H_{02}] \text{ e } F_2 = \frac{MQF_B}{MQR}$$

• Interação AB

$$H_{03} : \gamma_{11} = \gamma_{12} = \dots = \gamma_{21} = \dots = \gamma_{pq} = 0$$

H_{13} : existem diferenças significativas devido a interação

R.R : $F_3 > c$ com c (Fisher) determinado de

$$\alpha = Pr[F_{3(p-1)(q-1), pq(r-1)} > c; H_{03}] \text{ e } F_3 = \frac{MQI_{AB}}{MQR}$$

Tabela ANOVA

Fonte de variação	Soma dos Quadrados	graus de lib.	Média dos Quadrados	v.a F
Factor A	SQF_A	p-1	MQF_A	$F_1 = \frac{MQF_A}{MQR}$
Factor B	SQF_B	q-1	MQF_B	
Interação AxB	SQI_{AB}	(p-1).(q-1)	MQI_{AB}	$F_2 = \frac{MQF_B}{MQR}$
Resíduos	SQR	p.q.(r-1)	MQR	$F_3 = \frac{MQI_{AB}}{MQR}$
Total	STQ	pqr-1		

Testes não paramétricos

Teste de Kruskal-Wallis

H_0 : Não existem diferenças significativas entre os efeitos dos tratamentos ou as médias das distribuições das k populações são idênticas

H_1 : Nem todas as k distribuições têm médias idênticas.

R.R: $H \geq c$ onde c é determinado de $\alpha = Pr[H \geq c; H_0]$ e

$$H = \frac{12}{n(n+1)} \left[\frac{W_1^2}{n_1} + \frac{W_2^2}{n_2} + \dots + \frac{W_k^2}{n_k} \right] - 3(n+1) \text{ com } W_i = \sum_{j=1}^{n_i} R_{ij} \quad i = 1, 2, \dots, k$$

Para $k > 3$ ou n_1, n_2, \dots e/ou $n_i > 5$, a distribuição assintótica de H é a χ^2 com $k - 1$ graus de liberdade.

A 'estatística' ajustada é

$$H' = \frac{H}{1 - \frac{\sum_{j=1}^l q_j(q_j^2 - 1)}{n(n^2 - 1)}}$$

em que l é o número de conjuntos com observações repetidas existente e q_j é o número de elementos nesse conjunto j ($j = 1, \dots, l$). A 'estatística' H' tem ainda uma distribuição assintótica χ_{k-1}^2 .

Planeamento com blocos. Teste de Quade

Os dados consistem num conjunto de b variáveis aleatórias independentes a k dimensões

$(y_{i1}, y_{i2}, \dots, y_{ik}), i = 1, \dots, b$, chamadas blocos.

Os cálculos para este teste devem estar assim ordenados:

$$\begin{array}{lll} \text{Amplitude do bloco: } A_i & \text{Graduações do bloco de acordo} & \text{Matriz } S_{ij} \\ A_i = \max_j(y_{ij}) - \min_j(y_{ij}) & \text{com a sua amplitude: } R(A_i) & S_{ij} = R(A_i)[R(y_{ij}) - \frac{k+1}{2}] \end{array}$$

$R(y_{ij})$ - graduações das observações y_{ij} , $(j = 1, \dots, k)$

$$S_j = \sum_{i=1}^b S_{ij}; \quad SQT = \frac{1}{b} \sum_{j=1}^k S_j^2; \quad STQ = \sum_{i=1}^b \sum_{j=1}^k S_{ij}^2$$

Se não existirem observações repetidas, STQ reduz-se a

$$b(b+1)(2b+1)k(k+1)(k-1)/72.$$

Teste de hipóteses

H_0 : Não existem diferenças significativas entre os tratamentos

(ou, os efeitos dos tratamentos são idênticos)

H_1 : Pelo menos um dos tratamentos tende a conseguir valores observados maiores do que um outro tratamento.

R.R : $T > C$ onde C é um ponto crítico da distribuição F que corresponde ao nível de significância α ,

com $(k-1)$ e $(b-1)(k-1)$ graus de liberdade

$$T = \frac{(b-1)SQT}{STQ - SQT}$$

Comparações dois a dois

Os tratamentos i e j são considerados significativamente diferentes se

$$|S_i - S_j| > c \sqrt{\frac{2b(STQ - SQT)}{(b-1)(k-1)}}$$

sendo C o ponto crítico da distribuição t-Student, com $(b-1)(k-1)$ graus de liberdade que corresponde a uma região de rejeição de tamanho α (nível de significância)

Testes de ajuste de distribuições

Testes do tipo de Kolmogorov para pequenas amostras

$S(x)$ é a função de distribuição empírica que é definida como fracção dos X'_i s (elementos da amostra) que são menores ou iguais a X , para cada X ($-\infty < X < +\infty$)

Dados: $F^*(x)$ é uma função distribuição completamente especificada.

A. Teste bilateral	B. Teste unilateral	C. Teste unilateral
$H_0 : F(x) = F^*(x) \forall x$	$H_0 : F(x) \geq F^*(x)$	$H_0 : F(x) \leq F^*(x)$
$H_1 : F(x) \neq F^*(x)$	$H_1 : F(x) < F^*(x)$	$H_1 : F(x) > F^*(x)$
$T = \sup_x F^*(x) - S(x) $	$T^+ = \sup_x [F^*(x) - S(x)]$	$T^- = \sup_x [S(x) - F^*(x)]$

R.R: T (T^+ ou T^-) $> c$ com c calculado de $\alpha = \text{Prob}(\text{Rej } H_0; H_0) = \text{Prob}(T > c; H_0 \text{ de } \mathbf{A.})$.

Os pontos críticos da distribuição de T (T^+ ou T^-) correspondem a $p = 1 - \alpha$

Teste de Lilliefors para a Normal

DADOS: Os dados consistem numa amostra aleatória X_1, X_2, \dots, X_n de tamanho n associada com alguma função distribuição desconhecida $F(x)$.

H_0 : A amostra aleatória foi retirada de uma distribuição normal, com média e/ou variância não especificadas.

H_1 : A função distribuição dos X_i 's não é normal.

R.R: $T_1 > c$ sendo c o ponto crítico da distribuição de T_1 que corresponde a $p = 1 - \alpha$

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} \quad e \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$Z_i = \frac{X_i - \bar{X}}{s}, \quad i = 1, 2, \dots, n \quad T_1 = \sup_z |F^*(z) - S(z)|$$

Teste de Lilliefors para a exponencial

DADOS: Os dados consistem numa amostra aleatória X_1, X_2, \dots, X_n de tamanho n associada com alguma função distribuição desconhecida $F(x)$.

H_0 : A amostra aleatória segue a distribuição exponencial:

$$F(x) = F^*(x) = \begin{cases} 1 - e^{-x/\beta}, & \text{para } x > 0 \\ 0 & \text{para } x < 0 \end{cases}$$

em que β é um parâmetro desconhecido.

H_1 : A distribuição dos X_i 's não é exponencial.

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} \quad Z_i = \frac{X_i}{\bar{X}}, \quad i = 1, 2, \dots, n$$

$$F^*(z) = \begin{cases} 1 - e^{-z}, & \text{para } z > 0 \\ 0 & \text{para } z < 0 \end{cases}$$

$$T_2 = \sup_z |F^*(z) - S(z)|$$

R.R: $T_2 > c$ sendo c o ponto crítico da distribuição de T_2 que corresponde a $p = 1 - \alpha$.

Teste a duas distribuições. Amostras independentes.

Teste de Kolmogorov - Smirnov

DADOS: Os dados consistem em duas amostras aleatórias independentes, uma de tamanho n , X_1, X_2, \dots, X_n e outra de tamanho m , Y_1, Y_2, \dots, Y_m retiradas de duas populações com distribuições $F(x)$ e $G(y)$ (ou $G(x)$) respectivamente.

A. Teste bilateral	B. Teste unilateral	C. Teste unilateral
$H_0 : F(x) = G(x) \quad \forall x$	$H_0 : F(x) \leq G(x)$	$H_0 : F(x) \geq G(x)$
$H_1 : F(x) \neq G(x)$	$H_1 : F(x) > G(x)$	$H_1 : F(x) < G(x)$
$T_1 = \sup_x S_1(x) - S_2(x) $	$T_1^+ = \sup_x [S_1(x) - S_2(x)]$	$T_1^- = \sup_x [S_2(x) - S_1(x)]$

com $S_1(x)$ a função empírica baseada na amostra X_1, X_2, \dots, X_n e $S_2(x)$ a função empírica baseada em Y_1, Y_2, \dots, Y_m
R.R: T_1 (T_1^+ ou T_1^-) $> c$ sendo c o ponto crítico da distribuição da estatística que corresponde a um nível de significância α .

Teste a k distribuições. Amostras independentes. Teste unilateral de Smirnov

DADOS: k amostras aleatórias de tamanho iguais a n . Se as distribuições empíricas forem, respectivamente, $S_1(x), S_2(x), \dots, S_k(x)$, e as funções distribuição $F_1(x), F_2(x), \dots, F_k(x)$ representam as k populações, desconhecidas,

$H_0 : F_1(x) \leq F_2(x) \leq \dots \leq F_k(x)$ para todo o x

$H_1 : F_i(x) > F_j(x)$ para algum $i < j$ e algum x

R.R: $T_2 > c$ sendo c o ponto crítico, que corresponde a $p = 1 - \alpha$, ao nível de significância α .

$$T_2 = \sup_{x, i < k} [S_i(x) - S_{i+1}(x)] \quad i = 1, \dots, k-1$$

Regressão linear e simples

$$Y_i \sim N(\alpha + \beta x_i, \sigma^2)$$

$$Y_i = \alpha + \beta x_i + e_i \quad \text{com} \quad x_i = X_i - \bar{X}, \quad i = 1, \dots, n$$

Os estimadores de máxima verossimilhança, para os parâmetros α, β e σ^2 são

$$\tilde{\alpha} = \frac{\sum_{i=1}^n Y_i}{n} = \bar{Y} \quad ; \quad \tilde{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2},$$

$$\tilde{\sigma}^2 = \frac{1}{(n-2)} \sum_{i=1}^n [Y_i - \tilde{\alpha} - \tilde{\beta}(X_i - \bar{X})]^2$$

Testes de hipóteses

$$T_1 = \frac{\tilde{\alpha} - \alpha}{\sqrt{\frac{\tilde{\sigma}^2}{n}}} \sim t_{n-2} \quad ; \quad T_2 = \frac{\tilde{\beta} - \beta}{\sqrt{\frac{\tilde{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}} \sim t_{n-2}$$

$$H_0 : \beta = 0$$

$$H_1 : \beta > 0 \quad (\text{ou} \quad \beta \neq 0)$$

$$\text{R.R:} \quad T_2 \geq c \quad \text{com} \quad c = t_{n-2, \alpha} \quad (\text{ou} \quad \alpha/2)$$

Do mesmo modo, a 'estatística' T_1 pode ser usada para calcular intervalos de confiança e testes de hipóteses relacionados com o parâmetro α

Média e variância de um valor estimado de Y :

$$E[Y_0] = E[\tilde{\alpha}] + (X_0 - \bar{X})E[\tilde{\beta}] = \alpha + \beta(X_0 - \bar{X})$$

$$\text{var}[Y_0] = \sigma^2 \left(\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

Regressão linear e múltipla

$$Y_i = \alpha + \beta x_i + \gamma z_i + e_i$$

em que $x_i = X_i - \bar{X}$, $z_i = Z_i - \bar{Z}$ e e_i é o erro aleatório de observação, normalmente distribuído com média zero e variância comum σ^2 ($i = 1, \dots, n$).

$$E[Y] = \alpha + \beta(X - \bar{X}) + \gamma(Z - \bar{Z}).$$

$$\tilde{\alpha} = \frac{\sum_{i=1}^n Y_i}{n} = \bar{Y} \quad ; \quad \tilde{\sigma}^2 = \frac{1}{(n-3)} \sum_{i=1}^n (Y_i - \tilde{\alpha} - \tilde{\beta}x_i - \tilde{\gamma}z_i)^2$$

$$\begin{cases} \sum_{i=1}^n x_i Y_i = \tilde{\beta} \sum_{i=1}^n x_i^2 + \tilde{\gamma} \sum_{i=1}^n x_i z_i \\ \sum_{i=1}^n z_i Y_i = \tilde{\beta} \sum_{i=1}^n x_i z_i + \tilde{\gamma} \sum_{i=1}^n z_i^2 \end{cases}$$

As 'estatísticas' T_1, T_2 e T_3 para testes de hipóteses e intervalos de confiança, em relação,

respectivamente, aos parâmetros α, β e γ , são:

$$T_1 = \frac{\tilde{\alpha} - \alpha}{\sqrt{\frac{\tilde{\sigma}^2}{n}}}; \quad T_2 = \frac{\tilde{\beta} - \beta}{\sqrt{\frac{\tilde{\sigma}^2}{\sum x_i^2 - \frac{(\sum x_i z_i)^2}{\sum z_i^2}}}}; \quad T_3 = \frac{\tilde{\gamma} - \gamma}{\sqrt{\frac{\tilde{\sigma}^2}{\sum z_i^2 - \frac{(\sum x_i z_i)^2}{\sum x_i^2}}}} \text{ e seguem a distribuição t-Student com}$$

$n - 3$ graus de liberdade.

Regressão não-linear

i) $E[Y_i] = \alpha + \beta X_i^2$

O modelo matemático geral, é: $Y_i = \alpha + \beta w_i + \gamma w_i^2 + e_i$ com $w_i = W_i - \bar{W}$ e $e_i \sim N(0, \sigma^2)$ ($i = 1, \dots, n$). Define-se $X = W$ e $Z = W^2$, o que reduz este caso à regressão múltipla e linear.

ii) $E[Y_i] = X_i^\beta$

O modelo matemático mais geral e comum é: $Y_i = \alpha e^{\beta X_i} u_i$. Os erros aleatórios u_i ($i = 1, \dots, n$) têm agora uma distribuição, em geral não simétrica e centrada em 1.

Lineariza-se o modelo passando-se a ter: $\ln Y_i = \ln \alpha + \beta X_i + \ln u_i$ e aplica-se a análise de regressão linear e simples.

Testes de independência estocástica

• Coeficiente de correlação da amostra. Teste de Pearson

$$X \sim N(\mu_1, \sigma_1^2) \text{ e } Y \sim N(\mu_2, \sigma_2^2)$$

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$

$$\text{R.R: } |R| \geq c. \text{ O valor de } c \text{ é determinado de } \alpha = P_r[|R| \geq c; H_0]$$

$$R = \frac{\sum_{i=1}^n X_i Y_i - \frac{\sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{n}}{\sqrt{(\sum_{i=1}^n X_i^2 - \frac{(\sum_{i=1}^n X_i)^2}{n})(\sum_{i=1}^n Y_i^2 - \frac{(\sum_{i=1}^n Y_i)^2}{n})}}$$

e que é o coeficiente de correlação da amostra de Pearson.

A variável $T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t_{n-2}$ e o teste resume-se a, rejeitar H_0 se $|T| \geq c$ com c determinado de $\alpha = P_r[|T| \geq c; H_0]$.

• Correlação de Spearman

$(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ amostra aleatória bivariada, de tamanho n

$R(X_i)$ graduação do valor de X_i

$R(Y_i)$ graduação do valor de Y_i ($i = 1, 2, \dots, n$)

A medida de correlação de Spearman R_S é definida por

$$R_S = \frac{\sum_{i=1}^n [R(X_i) - \frac{n+1}{2}][R(Y_i) - \frac{n+1}{2}]}{\frac{n(n^2-1)}{12}}$$

ou

$$R_S = 1 - \frac{6T}{n(n^2-1)} \quad \text{com} \quad T = \sum_{i=1}^n [R(X_i) - R(Y_i)]^2$$

caso não existam observações repetidas. Existindo repetições deve usar-se a expressão:

$$R_S = \frac{\sum_{i=1}^n R(X_i)R(Y_i) - n(\frac{n+1}{2})^2}{\sqrt{\sum_{i=1}^n R(X_i)^2 - n(\frac{n+1}{2})^2} \cdot \sqrt{\sum_{i=1}^n R(Y_i)^2 - n(\frac{n+1}{2})^2}}$$

A. Teste bilateral

H_0 : As variáveis X e Y são independentes.

H_1 : (a) Existe uma tendência para os maiores valores de X formarem pares com os maiores valores de Y , ou

(b) Existe uma tendência para os menores valores de X formarem pares com os maiores valores de Y .

R.R: $R_S > c_1$ ou $R_S < c_2$, sendo c_1 o ponto crítico que corresponde a $1 - \frac{\alpha}{2}$ e c_2 o ponto crítico que corresponde a $\frac{\alpha}{2}$

B. Teste unilateral para correlação positiva

H_0 : As variáveis X e Y são independentes.

H_1 : Existe uma tendência para os maiores valores de X e de Y formarem pares.

R.R: $R_S > c$, em que c é o ponto crítico que corresponde a $1 - \alpha$

C. Teste unilateral para correlação negativa

H_0 : As variáveis X e Y são independentes.

H_1 : Existe uma tendência para os menores valores de X formarem pares com os maiores valores de Y e vice-versa.

R.R: $R_S < c$ sendo c o ponto crítico que corresponde a α .